Sim, Min Kyu, Ph.D. mksim@seoultech.ac.kr



데이터 시각화 1 / 41 RO2. R Basics

- Data Type
- Data Structure
- Control Statement
- Base Cheatsheet

데이터 시각화 2 / 41 R02. R Basics

Data Type

•00000000000

Data Type

데이터 시각화 3 / 41 R02. R Basics

Motivation

주민등록번호



- 하나의 문자열로 보이는 주민등록번호에 의미적으로 여러가지 data type이 담겨있다.
- 주민등록번호는 "숫자"가 아니다. ("숫자"는 사칙연산이 가능해야 한다.)
- Data Type(문자, 날짜, 분류, 숫자)에 따라 다루는 방법이 다르다.

데이터 시각화 4 / 41 R02. R Basics

Data Type

R Data Types

- 1. character (string)
- numeric
- logical
- 4. factor
- 5. Date
- 6. and many others...

데이터 시각화 5 / 41 RO2. R Basics

1. character (string)

```
greeting <- "R says \"Hello World!\""
nchar(greeting) # number of characters
## [1] 21
substr(greeting, 3, 6) # substring from 3rd to 6th
## [1] "says"
greeting # show
## [1] "R says \"Hello World!\""
cat(greeting) # show cLeanly
## R says "Hello World!"</pre>
```

Random tips

- 따옴표를 입력할때는 backslash를 앞에 붙여준다.
- substr은 SUBset of STRing, 문자열의 부분 집합을 추출한다.
- cat 함수를 사용하면 backslash를 빼고 출력한다.

```
paste0(string1, string2); paste(string1, string2, sep)
nchar(string); substr(string, start, end); cat(string)
```

데이터 시각화 6 / 41 R02. R Basics

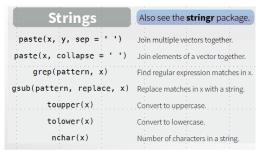


그림 1: base 패키지에서 제공하는 string 처리 함수

- base 패키지의 함수들 외에도
- stringr, stringi의 패키지가 string 처리 함수들을 제공한다.
- tidyverse 패키지는 stringr, stringi 패키지를 포함한다.

데이터 시각화 7 / 41 RO2. R Basics

Data Type

2. numeric

 $10^2 + 36$

```
## [1] 136
a <- 4
а
## [1] 4
a*5
## [1] 20
a <- a + 10 # assign a+10 to a
а
## [1] 14
```

• 일반 계산기 처럼 사용할 수 있다.

데이터 시각화 8/41 R02. R Basics

3. Logical

- 참과 거짓 (TRUE와 FALSE)
- TRUE는 수치형의 1, FALSE는 수치형의 0에 대응된다.

```
2==3
```

[1] FALSE

5>3

[1] TRUE

as.numeric(2==3)

[1] 0

a == b	Are equal	a > b	Greater than	a >= b	Greater than or equal to	is.na(a)	Is missing
a != b	Not equal	a < b	Less than	a <= b	Less than or equal to	is.null(a)	Is null

그림 2: logical 값을 반환하는 수치 비교 함수

데이터 시각화 9 / 41 RO2. R Basics

Data Type의 확인과 변환

- is.DATATYPE() 함수
 - 해당 DATATYPE이 맞으면 TRUE, 아니면 FALSE값을 반환한다.
- as.DATETYPE() 함수
 - 인수를 DATATYPE으로 변환하여 반환한다.

```
## [1] FALSE
is.character("5")
## [1] TRUE
a <- as.character(5)
is.character(a)
## [1] TRUE
b <- as.numeric(a)
is.numeric(b)
## [1] TRUE</pre>
```

as.numeric(2==3) ## [1] 0

is.character(5)

데이터 시각화 10 / 41 RO2. R Basics

- class()함수
 - 인수의 Data Type을 반환한다.

```
class(5)
```

```
## [1] "numeric"
class("TRUE")
```

[1] "character"
class(TRUE)

[1] "logical"

데이터 시각화 11 / 41 RO2. R Basics

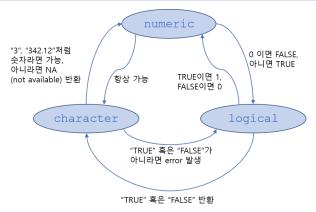


그림 3: string-numeric-logical간의 변환

- 함수들 마다 제각각
 - 입력(input)에 해당하는 인수(argument)의 지정된 data type이 있다.
 - 출력(output)값도 지정된 data type으로 반환된다.
 - 그러므로 data type을 확인하고 변환할 수 있어야 한다.

데이터 시각화 12 / 41 RO2. R Basics

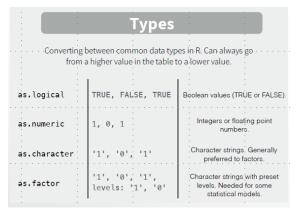


그림 4: Base Cheatsheet의 data type 관련 부분

- 위에서 아래 방향으로는 언제나 변환이 가능하다.
- 데이터 타입의 개수는 매우 많다.
- 새로운 응용프로그램 (패키지)마다 적합한 타입을 정의하기도 한다.
- 마주칠때마다 검색하고 필요한 만큼 알아보고 사용한다.

데이터 시각화 13 / 41 R02. R Basics

4. factor (Categorical, 범주형 변수)

Group을 나타내는 data type

- Keywords
 - "Partition", "Classification", "분류", "집단", "Group", "범주"
- 예시
 - 성인남자, 성인여자, 미성년자
 - 표준 산업 분류 (제조업, 금융업, 광공업등)
 - 날씨 (맑음, 흐림, 비가 옴)
- 생성
 - data.frame생성시에 stringsAsFactors = TRUE를 사용하면 모든 문자 객체가 factor가 됨
 - 다른 data type에서 as.factor()를 이용해서 변환

다른 data type과의 차이

- 숫자 vs categorical
 - 더하고 뺄 수 있다면 numeric
 - 1,2,3을 A,B,C로 바꿔도 무리가 없다면 categorical
- 문자 vs categorical
 - Exclusive (배타적) 집합이고, 각 개체가 1개의 그룹에 속한다면 categorical

데이터 시각화 14 / 41 R02. R Basics

Data Structure

데이터 시각화 15 / 41 R02. R Basics

자료형 (data type) vs 자료구조 (data structure)

Data type

- 변수에 입력된 하나의 값의 특성
- 0차원, 하나의 점, 하나의 값, singleton

Data Structure

- 묶어서 보관/처리하기 위해서 필요
- 각각의 값(singleton)들이 모여 있는 구조
- 대용량 데이터도 한 번에 포함할 수 있기에 데이터 분석에서 중요
- 엑셀에서 1개의 컬럼, 1개의 네모 블럭, 1개의 워크시트, 1개의 파일 모두 자료 구조에 해당

자료 구조의 이해

- 1. 길다란가? 네모난가? 삐뚤빼뚤한다?
- 2. 몇 개의 관찰값이 있는가?
- 3. 어떤 규칙을 가지고 있는가?

데이터 시각화 16 / 41 R02. R Basics

Data Structure의 종류

- 1. vector
- 2. array (matrix)
- 3. data.frame
- 4. list

데이터 시각화 17 / 41 R02. R Basics

1. vector

- 길다랗게 저장되어 있는 데이터 구조
- c()함수를 이용해서 벡터를 생성

Character vectors

- paste함수는 string으로 된 vector에도 적용이 가능하다.
- seq() 함수는 등차 수열을 만든다.

strVec1 <- c("Hello", "Hi", "What's up")

• a:b는 a부터 b까지의 정수 벡터를 만든다.

```
strVec1
## [1] "Hello" "Hi" "What's up"
strVec2 <- c("Ma'am", "Sir", "Your Honor")
strVec3 <- paste(strVec1, strVec2, sep = ", ")
strVec3
## [1] "Hello, Ma'am" "Hi, Sir"</pre>
```

"What's up, Your Honor"

데이터 시각화 18 / 41 R02. R Basics

```
    Numeric vectors
```

```
numVec1 <- c(30,50,70)
numVec1
## [1] 30 50 70
numVec2 \leftarrow seg(30,70,20)
numVec2
## [1] 30 50 70
numVec3 \leftarrow c(25,55,80)
numVec3
## [1] 25 55 80
numVec4 \leftarrow seq(from=20, to=1, by=-3)
numVec4
## [1] 20 17 14 11 8 5 2
2:6
## [1] 2 3 4 5 6
```

min vs pmin?

```
min(numVec1) # by all

## [1] 30
min(numVec1, numVec3) # by all

## [1] 25
pmin(numVec1, numVec3) # by element

## [1] 25 50 70
numVec1 > numVec3 # by element

## [1] TRUE FALSE FALSE

• subsetting
```

```
## [1] 50
numVec1[-2]
## [1] 30 70
numVec1[1:2]
## [1] 30 50
numVec1[c(1,3)]
```

numVec1[2]

2. array (matrix)

[2,] 2 4 6

구조

- 동일한 data type의 벡터를 쌓아서 만든 데이터 구조
- (2D) 직각사각형의 데이터 구조
- (3D) 직육면체의 데이터 구조

생성

- matrix() 또는 array()함수로 생성
 - data = c(9,2,3,4,5,6)로 element들을 나열
 - ncol = 3으로 3개의 컬럼을 가진 matrix 생성 (Number of COLumn)
 - nrow로도 만들 수 있음 (Number of ROW)

```
mat <- matrix(data = c(9,2,3,4,5,6), ncol = 3)
mat
## [,1] [,2] [,3]
## [1,] 9 3 5</pre>
```

데이터 시각화 20 / 41 R02. R Basics

Subsetting

• vector와 같은 방식으로 subsetting

```
mat[1, 2] # first row, second column
## [1] 3
mat[2, ] # second row
## [1] 2 4 6
```

데이터 시각화 21 / 41 RO2. R Basics

여러가지 방식으로 연산이 가능

- 원소단위, 행 단위, 열단위에 함수를 적용할 수 있다.
- mean()은 전체 element들에 대해서 평균을 구함
- apply(MATRIX, 2, FUNCTION)
 - MATRIX의 각 column에 FUNCTION을 apply
- apply(MATRIX, 1, FUNCTION)

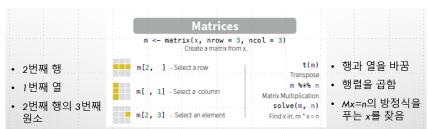
[1] 5.666667 4.000000

• MATRIX의 각 row에 FUNCTION을 apply

```
mat
## [,1] [,2] [,3]
## [1,] 9 3 5
## [2,] 2 4 6
mean(mat)
## [1] 4.833333
apply(mat, 2, mean) # colMeans(mat)
## [1] 5.5 3.5 5.5
apply(mat, 1, mean) # rowMeans(mat)
```

- apply() 함수는 왜 어렵게 느껴질까요?
 - 함수의 argument로 함수가 들어가서 어렵게 느껴짐
 - 과거에는 apply()계열의 함수를 편리하게 사용할 수 있다면 중급사용자로 판단하기도 함
 - dplyr, tidyr 등의 패키지의 함수들은 간편한 방식의 data wrangling 기능을 제공한다.

데이터 시각화 22 / 41 RO2. R Basics



Data Type

그림 5: Base Cheatsheet의 matrix관련 부분

데이터 시각화 23 / 41 R02. R Basics

3. data.frame

- vector를 모아서 네모낳게 만든 것이 data.frame
 - data.frame() 함수를 이용
 - date, sky, temp, dust vector가 weather라는 data.frame의 column이 됨
 - data.frame을 생성할 때는 stringsAsFactors = FALSE 옵션을 넣어줌
 - (그렇지 않으면 string이 factor로 저장됨)

weather

```
## date sky temp dust
## 1 2017-8-31 Sunny 20 24
## 2 2017-9-1 Cloudy 15 50
## 3 2017-9-2 Rainy 18 23
```

• 엑셀과는 어떤 차이점이 있나요?

데이터 시각화

- Column name과 Row name이 지정됨.
- 즉, 데이터프레임 weather의 첫 번째 행, 첫 번째 열의 원소는 2017-08-31이다.

- 각 column은 변수에 해당하고 이름도 보존된다.
- colnames()로 data.frame의 각 column의 이름을 확인할 수 있다.
- weather\$sky와 같이 특정 column을 이름을 사용해서 선택 가능
- weather[,2]와 같이 matrix의 subsetting 방법도 적용이 가능하다. 물론 weather\$sky로 적는 것이 좋은 코딩 스타일이다.

colnames(weather)

[1] "date" "sky" "temp" "dust"

weather\$sky

[1] "Sunny" "Cloudy" "Rainy"

weather\$sky==weather[,2]

[1] TRUE TRUE TRUE

- 엑셀에서는 A열, B열, 2행, 3행 이렇게 column과 row를 정의했었지만…
- data.frame에서는 colnames()과 rownames()로 고유의 이름을 부여한다.

데이터 시각화 25 / 41 RO2. R Basics

- class()함수는 앞에서 다룬 data type
 뿐 아니라 data structure를 확인하는
 데에도 쓰인다.
- class(VECTOR)의 경우에는 vector
 내의 각 element들의 data type을
 확인할 수 있는데…
- sapply()를 data.frame에 적용하면
 각 column에 같은 함수를 적용
- sapply()는 apply계열 함수중에서
 "simple apply"를 의미한다.

```
class(weather)
## [1] "data.frame"
class(weather$date)
## [1] "character"
sapply(weather, class)
## date sky temp dust
```

"numeric"

"character" "character"

• date 벡터의 data type이 character 이므로 Date로 변환해보자.

```
weather$date <- as.Date(weather$date)
sapply(weather, class)

## date sky temp dust
## "Date" "character" "numeric" "numeric"</pre>
```

"numeric"

str(weather)

\$ dust: num 24 50 23

• str()은 데이터의 구조를 보여주는 함수이다.

```
## 'data.frame': 3 obs. of 4 variables:
## $ date: Date, format: "2017-08-31" "2017-09-01" ...
## $ sky : chr "Sunny" "Cloudy" "Rainy"
## $ temp: num 20 15 18
```

데이터 시각화 27 / 41 R02. R Basics

Data Type

그림 6: Base Cheatsheet의 data frame관련 부분

데이터 시각화 28 / 41 RO2. R Basics

4. list

```
HMSon <-
  list(team = c("Korea", "Tottenham"),
       birth = as.Date("1992-07-08"),
       goals =
         data.frame(team = c("U-17", "U-23", "A"),
                    goals = c(4, 2, 7),
                    stringsAsFactors = FALSE))
HMSon
## $team
## [1] "Korea"
                   "Tottenham"
##
## $birth
## [1] "1992-07-08"
##
## $goals
     team goals
## 1 II-17
## 2 II-23
              2
## 3
```

- list()로 다양한 데이터 구조를 함께 묶을 수 있다.
- 사용하기 어렵지만, 때로는 불가피하고 유용하다.

• str()로 tree형 구조를 파악할 수 있다.

```
str(HMSon)
## List of 3
## $ team : chr [1:2] "Korea" "Tottenham"
## $ birth: Date[1:1], format: "1992-07-08"
## $ goals: 'data.frame': 3 obs. of 2 variables:
## ..$ team : chr [1:3] "U-17" "U-23" "A"
## ..$ goals: num [1:3] 4 2 7
```

- 이런 데이터 구조가 야근의 주범
- list형으로 데이터를 만들어야 한다면, 다시 한 번 잘 생각해본다. 정말로 불가피 한지…

데이터 시각화 30 / 41 R02. R Basics

• names()로 level-1 객체(바로 하위 레벨)의 이름 파악

```
names(HMSon)
```

```
## [1] "team" "birth" "goals"
```

• sapply()로 level-1 객체(바로 하위 레벨)에 동시에 함수 적용

sapply(HMSon, class)

```
## team birth goals
## "character" "Date" "data.frame"
```

데이터 시각화 31 / 41 RO2. R Basics

HMSon[3]

• []로 subsetting 하면 여전히 list

```
## $goals
## team goals
## 1 U-17     4
## 2 U-23     2
## 3     A     7
class(HMSon[3])
## [1] "list"
```

• [[]]로 subsetting 하면 level-1 객체를 반환

```
HMSon[[3]]
    team goals
## 1 U-17
## 2 II-23
## 3
HMSon[["goals"]]
    team goals
## 1 U-17
## 2 U-23
## 3
HMSon$goals
    team goals
## 1 II-17
## 2 11-23
## 3
     Α
class(HMSon[[3]])
## [1] "data.frame"
```

데이터 시각화 RO2. R Basics

- sapply(): "simple" apply
 - 바로 하위 구조에 함수를 apply 한다.
 - ullet data.frame o 데이터프레임의 level-l 객체인 원소, 즉, 각각의 컬럼에 적용
 - list → 리스트의 level-l 객체인 각 원소에 적용
 - vector → 벡터의 level-l 객체인 각 원소에 적용

데이터 시각화 33 / 41 RO2. R Basics



 List의 element는 서로 다른 type과 길이일 수 있습니다.

- I의 두번째 element (y가 벡터로 반환됨)
- I의 첫번째 element (x가 list로 반환됨)

element

• 1\$x 원소중 x라는 이름을 가진 것을 반환 (x가 vector로 반환됨)

named v.

• I중에서 이름이 y인 것을 반환 (y가 list로 반환됨)

그림 7: Base Cheatsheet의 list관련 부분

데이터 시각화 34 / 41 RO2. R Basics

자료 구조 Summary

- Dimension: 점(0D), 선(1D), 면(2D)
- Homogeneous (동질성): level-I의 길이와 type이 같으면 동질적이다.
- Heterogenous (이질성): 동질적이지 않으면 이질적이다.

Dimension	Homogenous	Heterogenous		
0D	element	N/A		
1D	vector	list		
>= 2D	array	data.frame		

• vector와 data.frame가 데이터 분석에서 흔히 자주 사용되는 구조이다.

데이터 시각화 35 / 41 R02. R Basics

Data Type

Control Statement

•0

데이터 시각화 36 / 41 R02. R Basics

Control Statement

```
for (variable in sequence){
                                           while (condition){
  Do something
                                              Do something
              Example
                                                          Example
for (i in 1:4){
                                           while (i < 5){
   j < -i + 10
if (condition){
                                            function name <- function(var){
  Do something
                                              Do something
} else {
  Do something different
                                              return(new variable)
              Example
                                                          Example
if (i > 3){
                                           square <- function(x){}
  print('Yes')
                                              squared <- x*x
} else {
  print('No')
```

그림 8: Control Statements

데이터 시각화 RO2. R Basics

Data Type

Base Cheatsheet

데이터 시각화 38 / 41 R02. R Basics



?mean Get help of a particular function. help.search('weighted mean') Search the help files for a word or phrase.

help(package = 'dplyr') Find help for a package. More about an object

str(iris) Get a summary of an object's structure.

class(iris) Find the class an object belongs to.

Using Packages

install.packages('dplyr') Download and install a package from CRAN.

library(dplyr) Load the package into the session, making all its functions available to use.

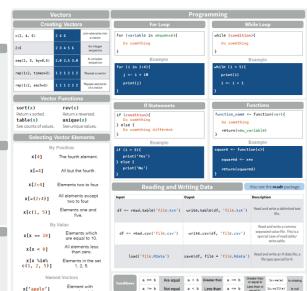
dplvr::select Use a particular function from a package.

data(iris) Load a built-in dataset into the environment

getwd() Find the current working directory (where inputs are found and outputs are sent).

setwd('C://file/path') Change the current working directory.

Use projects in RStudio to set the working directory to the folder you are working in.

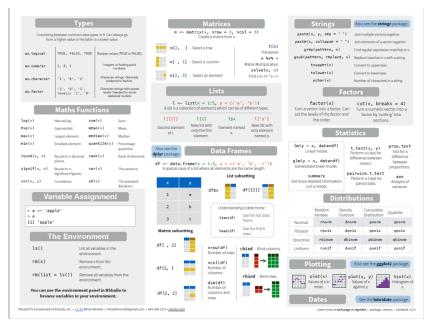


RStudio* is a trademark of RStudio, inc. • CC BY Mhairi McNeill • mhairifrmcneili@gmail.com

equal to Learn more at web page or vignette « package version » Updated: 3/15

데이터 시각화 39 / 41 RO2 R Basics

name 'apple'



데이터 시각화 40 / 41 R02. R Basics

Suggested Readings

- R for Data Science
 - https://r4ds.had.co.nz/
- [R4DS] Ch2. Workflow: Basics
 - https://r4ds.had.co.nz/workflow-basics.html
- [R4DS] Ch4. Workflow: Scripts
 - https://r4ds.had.co.nz/workflow-scripts.html
- [R4DS] Ch11. Strings with stringr
 - https://r4ds.had.co.nz/strings.html
- [R4DS] Ch12. Factors with forcats
 - https://r4ds.had.co.nz/factors.html
- [R4DS] Ch15. Functions
 - https://r4ds.had.co.nz/functions.html
- [R4DS] Ch16. Vectors
 - https://r4ds.had.co.nz/vectors.html

데이터 시각화 41 / 41 R02. R Basics