R05 Data Transformation dpLyr library

Sim, Min Kyu, Ph.D. mksim@seoultech.ac.kr



데이터 시각화 1/41 R05 Data Transformation

- 1. Library (or, package)
- II. Carseats 데이터셋 (@ISLR library)
- III. dplyr package
- 4 IV. Basic Manipulations
- V. Summary

데이터 시각화 2 / 41 R05. Data Transformation

•000

I. Library (or, package)

데이터 시각화 3/41 R05. Data Transformation

Library

0000

I. Library (or, package)

정의

- 응용 프로그램, 확장 프로그램, package
- 데이터나 함수의 모음

R의 library

- R을 처음에 설치하면 base라는 library가 설치되어있음
- base외의 확장 기능을 제공하는 패키지를 설치하여 사용
- 본 강의에서는 rmarkdown, dplyr, tidyr, ggplot2 등의 패키지 등을 다룸
- tidyverse는 데이터 분석에 관련된 여러 library를 모아둔 패키지이며, 하나같이 사용성이 좋음

Library의 중요성

- 오픈 소스 기반 언어(R, Python 등)는 누구나 패키지를 만들고 공유할 수 있음
- 많은 사람들이 많은 패키지를 만들면서 언어의 발전이 일어남

데이터 시각화 4/41 R05 Data Transformation

Library의 위상

I. Library (or, package)

0000

• Library는 Environment하에서 특정 기능을 제공하는 software에 해당한다.

Environment (환경)	Application (응용프로그램)
윈도우	Excel
안드로이드	카카오톡
R	dplyr, ggplot2, rmarkdown
Python	pandas, numpy

데이터 시각화 5 / 41 R05. Data Transformation

1. 설치

000

I. Library (or, package)

- base외의 패키지를 사용하려면 설치를 먼저 해주어야 함
- Ex) Playstore에서 카카오톡을 다운 받아 설치하는 것과 같음
- 따옴표를 넣어서 패키지의 이름을 입력

```
install.packages("package_name")
install.packages("dplyr") # this lecture is about
```

2. 사용 선언

- 패키지를 사용을 선언한 후에 패키지를 사용할 수 있음
- 이를 "declare", "import", "load"라고 표현
- Ex) 카카오톡의 사용을 위해서 카카오톡 아이콘을 클릭하는 것과 같음
- 따옴표 없이 아래처럼 입력

```
library(package_name)
library(dplyr) # this lecture is about
```

데이터 시각화 6 / 41 R05. Data Transformation

II. Carseats 데이터셋 (@ISLR library)

데이터 시각화 7 / 41 R05. Data Transformation

ISLR package

About the book

- 기계학습을 다루는 훌륭한 입문서 (An Introduction to Statistical Learning (ISLR))의 데이터셋과 함수를 모아둔 패키지
- 웹페이지
 - http://faculty.marshall.usc.edu/gareth-james/ISL/
- MOOC
 - https://www.r-bloggers.com/in-depth-introduction-to-machine-learning-in-15-hours-of-expert-videos/





ISLR::Carseats

- ISLR 패키지의 Carseats라는 데이터셋 사용
 - Carseats을 분석하는 형식으로 이번 강의노트 구성
 - 수백개의 오프라인 매장에서 카시트를 판매하는 업체의 매장별 판매 데이터

install.packages("ISLR") # install when using for the first time library(ISLR)

데이터 시각화 9 / 41 R05. Data Transformation

1. Check the data structure

```
library(ISLR) # Load `ISLR` package
class(Carseats) # data structure
## [1] "data.frame"
dim(Carseats) # dimensions
## [1] 400 11
str(Carseats) # structural view
## 'data.frame': 400 obs. of 11 variables:
  $ Sales
                : num 9.5 11.22 10.06 7.4 4.15 ...
   $ CompPrice : num 138 111 113 117 141 124 115 136 132 132 ...
   $ Income
                : num 73 48 35 100 64 113 105 81 110 113 ...
  $ Advertising: num 11 16 10 4 3 13 0 15 0 0 ...
   $ Population : num 276 260 269 466 340 501 45 425 108 131 ...
   $ Price
                · num 120 83 80 97 128 72 108 120 124 124 ...
   $ ShelveLoc : Factor w/ 3 levels "Bad", "Good", "Medium": 1 2 3 3 1 1 3 2 3 3 ...
   $ Age
                : num 42 65 59 55 38 78 71 67 76 76 ...
   $ Education : num 17 10 12 14 13 16 15 10 10 17 ...
                : Factor w/ 2 levels "No", "Yes": 2 2 2 2 2 1 2 2 1 1 ...
## $ Urban
## $ US
                : Factor w/ 2 levels "No", "Yes": 2 2 2 2 1 2 1 2 1 2 ...
```

2. Take a quick look

```
colnames(Carseats) # column names
   [1] "Sales"
                      "CompPrice"
                                     "Income"
                                                   "Advertising" "Population"
                                                   "Education"
    [6] "Price"
                      "ShelveLoc"
                                     "Age"
                                                                  "Urban"
## [11] "US"
head(Carseats) # the first 6 observations
     Sales CompPrice Income Advertising Population Price ShelveLoc Age Education
##
## 1 9.50
                 138
                         73
                                      11
                                                276
                                                      120
                                                                 Bad
                                                                      42
                                                                                17
## 2 11.22
                 111
                         48
                                      16
                                                260
                                                       83
                                                                Good
                                                                      65
                                                                                10
## 3 10.06
                 113
                         35
                                      10
                                                269
                                                       80
                                                             Medium
                                                                     59
                                                                                12
## 4 7.40
                 117
                        100
                                       4
                                                466
                                                       97
                                                             Medium 55
                                                                                14
## 5 4.15
                 141
                         64
                                       3
                                                340
                                                      128
                                                                 Bad
                                                                     38
                                                                                13
## 6 10.81
                 124
                        113
                                      13
                                                501
                                                       72
                                                                 Bad
                                                                     78
                                                                                16
##
     Urban US
## 1
       Yes Yes
       Yes Yes
## 2
## 3
       Yes Yes
## 4
       Yes Yes
## 5
       Yes No
## 6
        No Yes
```

tail(Carseats, 8) # the Last 8 observations

```
##
       Sales CompPrice Income Advertising Population Price ShelveLoc Age Education
## 393 4.53
                    129
                             42
                                          13
                                                    315
                                                           130
                                                                     Bad
                                                                           34
                                                                                      13
## 394
        5.57
                    109
                             51
                                          10
                                                     26
                                                           120
                                                                  Medium
                                                                           30
                                                                                      17
## 395
       5.35
                    130
                             58
                                          19
                                                    366
                                                           139
                                                                     Bad
                                                                           33
                                                                                      16
## 396 12.57
                    138
                            108
                                          17
                                                    203
                                                           128
                                                                    Good
                                                                           33
                                                                                      14
## 397
        6.14
                    139
                             23
                                           3
                                                     37
                                                           120
                                                                  Medium
                                                                           55
                                                                                      11
## 398
        7.41
                    162
                             26
                                          12
                                                    368
                                                           159
                                                                  Medium
                                                                          40
                                                                                      18
## 399
        5.94
                    100
                             79
                                          7
                                                    284
                                                            95
                                                                           50
                                                                                      12
                                                                     Bad
## 400
        9.71
                    134
                             37
                                          0
                                                     27
                                                           120
                                                                    Good
                                                                           49
                                                                                      16
```

Urban US

393 Yes Yes

394 No Yes

395 Yes Yes

396 Yes Yes

397 No Yes

398 Yes Yes

399 Yes Yes

400 Yes Yes

3. Pop-up windows

View(Carseats) # a pop-up windows

데이터 시각화 12 / 41 R05. Data Transformation

4. Summary stats

##

summary(Carseats) # summary statistics

```
Sales
                        CompPrice
                                         Income
                                                       Advertising
##
##
    Min.
           : 0.000
                     Min.
                             : 77
                                    Min.
                                            : 21.00
                                                      Min.
                                                              : 0.000
    1st Qu.: 5.390
                     1st Qu.:115
                                    1st Qu.: 42.75
                                                      1st Qu.: 0.000
    Median : 7,490
                     Median :125
                                    Median : 69.00
                                                      Median : 5.000
##
           : 7.496
                             :125
                                            : 68.66
                                                      Mean
                                                              : 6.635
##
    Mean
                     Mean
                                    Mean
##
    3rd Qu.: 9.320
                      3rd Qu.:135
                                    3rd Qu.: 91.00
                                                      3rd Qu.:12.000
##
    Max.
           :16.270
                     Max.
                             :175
                                    Max.
                                            :120.00
                                                      Max.
                                                              :29,000
##
      Population
                         Price
                                      ShelveLoc
                                                        Age
                                                                      Education
##
    Min.
           . 10.0
                    Min.
                            . 24.0
                                     Bad
                                            . 96
                                                   Min.
                                                           :25.00
                                                                    Min.
                                                                           :10.0
##
    1st Qu.:139.0
                    1st Qu.:100.0
                                     Good
                                           : 85
                                                   1st Qu.:39.75
                                                                    1st Qu.:12.0
##
    Median :272.0
                    Median :117.0
                                     Medium:219
                                                   Median :54.50
                                                                    Median :14.0
           :264.8
                            :115.8
                                                          :53.32
                                                                           :13.9
##
    Mean
                    Mean
                                                   Mean
                                                                    Mean
    3rd Qu.:398.5
                     3rd Ou.:131.0
                                                   3rd Ou.:66.00
                                                                    3rd Ou.:16.0
##
##
    Max.
           :509.0
                     Max.
                            :191.0
                                                   Max.
                                                           :80.00
                                                                    Max.
                                                                           :18.0
##
    Urban
                US
##
    No :118
              No :142
##
    Yes:282
              Yes:258
##
##
##
```

데이터 시각화 13 / 41 R05. Data Transformation

5. 각 변수의 data type

```
sapply(Carseats, class)
##
         Sales
                 CompPrice
                                 Income Advertising
                                                     Population
                                                                       Price
     "numeric"
                 "numeric"
                              "numeric"
                                          "numeric"
                                                       "numeric"
                                                                   "numeric"
##
##
     ShelveLoc
                       Age
                              Education
                                              Urban
                                                              LIS
##
      "factor"
                 "numeric"
                              "numeric"
                                           "factor"
                                                        "factor"
```

6. 각 변수에 대해 중복값을 제거한 관찰값 갯수

sapply(Carseats, function(x) length(unique(x)))

```
Sales
                 CompPrice
                            Income Advertising Population
                                                                     Price
##
           336
                        73
                                    98
                                                28
                                                           275
                                                                       101
##
##
     ShelveLoc
                       Age
                             Education
                                             Urban
                                                            US
```

- ##● Shelveloc, Urban, Urban, US는 factor 변수로 되어있고, 각각 2개 혹은 3개의 category 구분에 대한 정보를 담고 있다.
 - 수치형으로 되어있는 Education도 factor형으로 바꾸는게 좋지 않을까?

데이터 시각화 14 / 41 R05. Data Transformation

1. Check the data structure

library(ISLR) # Load `ISLR` package class(Carseats) # data structure dim(Carseats) # dimensions str(Carseats) # structural view

2. Take a quick look

colnames(Carseats) # column names
head(Carseats) # the first 6 observations
tail(Carseats, 8) # the Last 8 observations

3. Pop-up windows

View(Carseats) # a pop-up windows

4. Summary stats

summary(Carseats) # summary statistics

- 5. 각 변수의 data type
- sapply(Carseats, class)
- 6. 각 변수에 대해 중복값을 제거한 관찰값 갯수 sapply(Carseats, function(x) length(unique(x)))

데이터 시각화 15 / 41 R05. Data Transformation

III. dplyr package

데이터 시각화 16/41 R05. Data Transformation

Background

- 1. 빠르고 쉽게 data.frame의 manipulation 기능을 제공
 - C로 만들어서 빠름
 - SQL와 유사한 직관적인 문법이라 쉬움

library(dplyr)

- 2. Authored by Hadley Wickham
 - Head Scientist, Rstudio
 - R for Data Science 저자, 통계학 박사
 - 본인이 작성한 패키지들을 포함한 tidyverse라는 운영
 - Youtube.com에 key note등 좋은 동영상 많음. 누나도 통계학과 교수



그림 1: Hadley Wickham



그림 2: Charlotte Wickham

데이터 시각화 17 / 41 R05. Data Transformation

Tidy data set

• dplyr은 tidy data.frame 자료 구조를 다루는 함수를 제공한다.

dplyr functions work with pipes and expect tidy data. In tidy data:



그림 3: tidy dataset (from dplyr cheatsheet)

- What is "tidy dataset"?
 - 1. data.frame의 자료 구조
 - 2. 각각의 row는 관찰값
 - 3. 각각의 column은 변수

About

- %>%로 입력
- dplyr에 포함된 magrittr 패키지에 포함된 연산자.
- 앞에서 부터 읽게 해주어 가독성을 높이고, consecutive한 연산을 순서대로 적을 수 있게 해줌
- f(x)와 x %>% f()가 같음 (x를 f의 인수로 집어 넣는다)
- f(x,y)와 x %>% f(y)가 같음 (x를 f의 첫 번째 인수로 집어 넣는다)

Why more intuitive?

- 1. 수리표현
 - $y = \sqrt{\sqrt{(x+1)^2 + y}} + y$ 을 처리하는 방식
- 2. 일반적인 입력 방식
 - y <- sqrt(sqrt((x+1)^2+y)+y)
- 3. Pipe를 이용한 입력 방식
 - y <- (x+1)^2 %>% add(y) %>% sqrt() %>% add(y) %>% sqrt()
 - 앞에서 부터 뒤로 읽고, 중첩되는 괄호가 없어짐

데이터 시각화 19 / 41 R05. Data Transformation

IV. Basic Manipulations

데이터 시각화 20 / 41 R05. Data Transformation

Overview

• 이번 노트에서는 아래의 6가지 명령어에 대해서 다룸

	What it does	Column/Row
1. rename	변수 이름 바꿈	Column의 이름 변경
2. filter	관찰값 추출	Row를 추출
3. select	변수 선택	Column을 선택
4. arrange	관찰값 정렬	Row를 정렬
5. mutate	변수 생성	Column을 생성
6. group_by & summarise	grouping 하여 분석	

데이터 시각화 21 / 41 R05. Data Transformation

1. rename (변수 이름 바꿈, Column의 이름을 바꿈)

dplyr

```
# RENAME `Sales` to `Revenue`
temp <- rename(Carseats, Revenue = Sales) # dplyr
colnames(temp)

## [1] "Revenue" "CompPrice" "Income" "Advertising" "Population"
## [6] "Price" "ShelveLoc" "Age" "Education" "Urban"
## [11] "US"</pre>
```

base

데이터 시각화 22 / 41 R05. Data Transformation

temp <- filter(Carseats, Income > 90) # dplyr

FILTER obs only if Income > 100

I. Library (or, package)

[1] 63 11

```
# SELECT the variables Income and Population
temp <- select(Carseats, Income, Population) # dplyr
temp <- Carseats %% select(Income, Population) # dplyr + pipe
temp <- Carseats[,c("Income", "Population")] # base
colnames(temp)
## [1] "Income" "Population"</pre>
```

Carseats <- arrange(Carseats, Price) # dplyr
Carseats <- Carseats %>% arrange(Price) # dplyr + pipe
Carseats <- Carseats[order(Carseats\$Price),] # base</pre>

```
head(Carseats %>% select(Income, Price))
       Income Price
##
## 43
           69
                 24
## 126
           78
                 49
## 368
          106
                 53
## 314
           81
                 54
## 172
          106
                 55
## 273
           33
                 63
```

Ascending (1-2-3)

I. Library (or, package)

```
# Descending (3-2-1)
Carseats <- arrange(Carseats, desc(Price)) # dplyr
Carseats <- Carseats %>% arrange(desc(Price)) # dplyr + pipe
Carseats <- Carseats %>% arrange(-Price) # dplyr + pipe
Carseats <- Carseats[order(Carseats$Price, decreasing = TRUE),] # base
head(Carseats %>% select(Income, Price))
```

```
##
       Income Price
## 166
           58
                191
## 175
                185
           24
## 192
           42
                173
## 316
           21
                171
## 270
           69
                166
## 311
           65
                166
```

"AdvPerCapita" "RevPerCapita"

dplvr

[11] "US"

```
Carseats <- mutate(Carseats,</pre>
               AdvPerCapita = Advertising/Population,
               RevPerCapita = Sales/Population)
# dplvr + pipe
Carseats <- Carseats %>%
  mutate(AdvPerCapita = Advertising/Population,
         RevPerCapita = Sales/Population)
# hase
Carseats$AdvPerCapita <- Carseats$Advertising/Carseats$Population
Carseats$RevPerCapita <- Carseats$Sales/Carseats$Population
# result check
colnames(Carseats)
   [1] "Sales"
                        "CompPrice"
                                       "Income"
                                                       "Advertising"
                                                                      "Population"
    [6] "Price"
                        "Shelveloc"
                                       "Age"
                                                       "Education"
                                                                      "Urhan"
```

```
# dplyr
Carseats <- mutate(Carseats, AgeClass = ifelse(Age>=60, "Silver", "non-Silver"))
# dplyr + pipe
Carseats <- Carseats %>% mutate(AgeClass = ifelse(Age>=60, "Silver", "non-Silver"))
# base
Carseats$AgeClass <- ifelse(Carseats$Age >= 60, "Silver", "non-Silver")
head(Carseats, 6)
##
       Sales CompPrice Income Advertising Population Price ShelveLoc Age Education
## 166 0.37
                   147
                           58
                                                 100
                                                       191
                                                                 Bad
                                                                     27
                                                                                15
## 175 0.00
                   139
                           24
                                        0
                                                 358
                                                       185
                                                              Medium 79
                                                                                15
## 192 6.67
                   156
                           42
                                       13
                                                 170
                                                       173
                                                                Good
                                                                     74
                                                                                14
## 316 6.39
                   131
                           21
                                        8
                                                 220
                                                       171
                                                                Good
                                                                      29
                                                                                14
## 270 5.01
                   159
                           69
                                        0
                                                 438
                                                       166
                                                              Medium 46
                                                                                17
## 311 9.53
                   175
                           65
                                                 419
                                                       166
                                                              Medium 53
                                                                                12
                                       29
##
      Urban
             US AdvPerCapita RevPerCapita
                                             AgeClass
## 166
        Yes Yes
                   0.07000000
                                0.00370000 non-Silver
## 175
         No No
                   0.00000000
                                0.00000000
                                              Silver
## 192
                   0.07647059
                              0.03923529
                                              Silver
        Yes Yes
## 316
        Yes Yes
                   0.03636364
                                0.02904545 non-Silver
## 270
        Yes No
                   0.00000000
                                0.01143836 non-Silver
## 311
        Yes Yes
                   0.06921241
                                0.02274463 non-Silver
```

데이터 시각화 28 / 41 R05. Data Transformation

Hypothesis

- Carseat 회사의 주요 구매층은 아이를 낳아서 키울 나이인 30대 연령층이다.
 - 1. (high income) 소득이 높은 도시이면서
 - 2. (young city) 평균 연령이 30대인 도시에
 - 3. (AdvPerCapita) 충분한 광고비를 지출하고 있는가?

```
focusCity <- Carseats %>%
  filter(Income > 100) %>% # 1. FILTER high income
  filter(Age >= 30 & Age < 40) %>% # 2. FILTER only young cities
  mutate(AdvPerCapita = Advertising/Population) %>% # 3. MUTATE averaging per capita
  select(Sales, Income, Age, Population, Education, AdvPerCapita) %>% # SELECT main variables
  arrange(Sales) # ARRANGE for better display
```

filter(Age >= 30 & Age < 40) %>% # 2. FILTER only young cities

mutate(AdvPerCapita = Advertising/Population) %>% # 3. MUTATE averaging per capita
select(Sales, Income, Age, Population, Education, AdvPerCapita) %>% # SELECT main variables

Successive transformation using pipe (%>%)

filter(Income > 100) %>% # 1. FILTER high income

I. Library (or, package)

focusCity <- Carseats %>%

```
arrange(Sales) # ARRANGE for better display
focusCity
##
       Sales Income Age Population Education AdvPerCapita
## 248
       5.04
                114
                     34
                                298
                                           16
                                                0.00000000
## 387
        5.32
                116
                     39
                                170
                                           16
                                                9.99999999
## 313
       6.80
                117
                     38
                                337
                                           10
                                                0.01483680
## 223
       7.49
                119
                     35
                                178
                                           13
                                                0.03370787
## 261
       7.67
                117
                     36
                                400
                                           10
                                                0.02000000
## 76
        8.55
                111
                     36
                               480
                                           16
                                                0.04791667
## 347 8.97
                107
                     33
                                                0.00000000
                                144
                                           13
## 173 9.03
                102
                     35
                                123
                                           16
                                                0.10569106
## 212 9.39
                118
                     32
                                445
                                           15
                                                0.03146067
## 255 9.58
                104
                     37
                                353
                                           17
                                                0.06515581
## 324 10.36
                105
                     34
                                428
                                           12
                                                0.04205607
## 221 10.59
                120
                     30
                                262
                                           10
                                                0.05725191
## 396 12.57
                108
                    33
                                203
                                           14
                                                0.08374384
```

데이터 시각화 30 / 41 R05. Data Transformation

248, 387, 347번 city에는 왜 광고를 하지 않는가하는 의문을 만들어 냄

6. group_by & summarise

```
Shelve effect <- Carseats %>%
 group_by(ShelveLoc) %>%
  summarize(count = n(), # Counting function
            avg Sales = mean(Sales)) %>% # Average of Sales
  arrange(avg Sales)
Shelve_effect
## # A tibble: 3 x 3
     ShelveLoc count avg Sales
##
##
     <fct>
               <int>
                         <dh1>
## 1 Bad
                  96
                          5.52
## 2 Medium
                 219
                          7.31
## 3 Good
                  85
                         10.2
```

Hypothesis and design

- 도시 인구의 평균 나이가 20대, 30대, 40대 이상인 경우에 Sales에 차이가 있다.
 - Step 1. AgeClass라는 categorical 변수 생성하고 (mutate & ifelse)
 - Step 2. AgeClass로 묶어서 (group_by)
 - Step 3. mean(Sales)로 집계하여 (summarise)
 - Step 4. 새로운 데이터셋 ageDiff를 만든다.

Implementation

데이터 시각화 32 / 41 R05. Data Transformation

Results

```
ageDiff <- Carseats %>%
 mutate(AgeClass = # Step 1
           ifelse(Age < 30, "Twenties",
                  ifelse(Age < 40, "Thirties", "FourtyAbove"))) %>%
 group by(AgeClass) %>% # Step 2
  summarise(count = n(),
            avg Sales = mean(Sales)) # Step 3
ageDiff
## # A tibble: 3 x 3
     AgeClass count avg Sales
##
     <chr>>
                 <int>
                           <dh1>
##
## 1 FourtyAbove
                   300
                            7.30
## 2 Thirties
                            8.26
                    63
## 3 Twenties
                    37
                            7.76
```

- 평균 연령이 30대인 도시에서 가장 매출이 높다.
- 그러므로 평균 연령이 30대인 도시에 광고비 집행을 증가시켜야 한다는 결론을 내릴 수 있다.

데이터 시각화 33 / 41 R05. Data Transformation

Discussion

- 위의 분석 결론이 놓치고 있는 점은 무엇인가?
- 어떤 분석이 추가적으로 수행되어야 하는가?
- 추가적인 분석을 위해서 필요한 데이터셋은 무엇인가? 확보전략은?
- 데이터분석가의 책임이 주어진 데이터를 분석하는 것으로 한정되면 안된다.

데이터 시각화 34 / 41 R05. Data Transformation

연속변수의 이산화

- 많은 데이터 분석은 "연속 변수"를 "이산 변수"로 생성하고,
- "이산 변수"의 group별 차이를 파악하는 접근을 사용한다.
 - 1. Age를 factor로 잡아 Sales의 Boxplot.
 - 2. Age를 factor로 잡아 scatterplot for Population & Sales.

가설 수립의 방향

- 1개 변수의 특징에 대해서 생각한다.
- 2개 변수의 관계에 대해서 생각한다.
- 3개 이상의 변수의 관계를 생각해본다.
- 공간과 시간에 대한 동질성과 이질성을 생각해본다.

데이터 시각화 36 / 41 R05. Data Transformation

V. Summary

Summary

What it does	Column/Row
변수 이름 바꿈	Column의 이름 변경
관찰값 추출	Row를 추출
변수 선택	Column을 선택
관찰값 정렬	Row를 정렬
변수 생성	Column을 생성
grouping 하여 분석	
	변수 이름 바꿈 관찰값 추출 변수 선택 관찰값 정렬 변수 생성

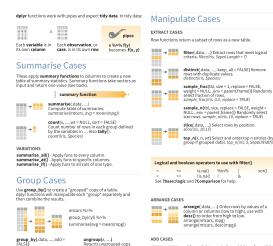
dplyr vs base

dplyr	base
 일상적 언어에 가까움 읽고 쓰기 쉬움 SOL	전통적인 프로그래밍 언어 타 언어와 유사한 스타일 Python의 Pandas

데이터 시각화 RO5. Data Transformation

Data Transformation with dplyr:: **CHEAT SHEET**





of table.

unaroup(a iris)

Returns copy of table

g_iris <- group_by(iris, Species)

Studio

grouped by ...

Manipulate Variables

considerations return a set of columns as a new vector or table.

pull (data, var = 1) Extract columns values as a vector. choose by parae or index. pullifors, Spot Length)

Extract columns as a table. Also select_H(). Setting (Columns as a table.)

Use these helpers with select (), e.g. select(iris, starts_with/"Sepa")) contains(match) num_range(prefix, range) ends, with(match) num_range(prefix, range) one_of(...) starts_with(match) , e.g. species matches (match) starts_with(match)

MAKE NEW VARIABLES

These apply vectorized functions to columns. Vectorized funs take vectors as input and return vectors of the same length as output (see back).

vectorized function



mutate_oll(faithful, funs(log(,), log2(,)))
mutate_if(iris, is.numeric, funs(log(,)))

mutate_at(,tbl, cols, funs, ...) Apply funs to specific columns. Use with funs(), wars() and the helper functions for select().
mutate_at(iris, vars(-Species), funs(log(,)))



RStudio* is a trademark of RStudio, Inc. - CC BY SARStudio - info@nstudio.com - 844-448-3232 - rstudio.com - Learn more with browsenignettes(package = c("dpt)yr", "bible")| - dptyr 0.7.0 - tibble 1.2.0 - Updated: 2017-23

add_row(.data, ..., .before = NULL, .after = NULL)

add_row(faithful, eruptions = 1, waiting = 1)

Add one or more rows to a table.

Vector Functions

TO USE WITH MUTATE ()

mutate() and transmute() apply vectorized functions to columns to create new columns. Vectorized functions take vectors as input and return vectors of the same length as output.

vectorized function

OFFSETS

dplyr::lag() - Offset elements by 1 dplyr::lead() - Offset elements by -1

CUMULATIVE AGGREGATES

dplyr::cumall() - Cumulative all() dplyr::cumany() - Cumulative any() cummax() - Cumulative max() dplyr::cummean() - Cumulative mean() cummin() - Cumulative min() cumprod() - Cumulative prod()

RANKINGS

cumsum() - Cumulative sum() dplyr::cume dist() - Proportion of all values <= dplyr::dense_rank() - rank with ties = min, no

dplyr::min rank() - rank with ties = min dplyr::ntile() - bins into n bins dplyr::percent rank() - min rank scaled to [0.1] dplyr::row_number() - rank with ties = "first"

МАТН

+, -, *, /, ^, %/%, %% - arithmetic ops log(), log2(), log10() - logs <, <=, >, >=, !=, == · logical comparisons dplyr::between() - x >= left & x <= right dplyr::near() - safe == for floating point numbers

dplyr::case when() - multi-case if else() dplyr::coalesce() - first non-NA values by element across a set of vectors dplyr::if_else() - element-wise if() + else() dplyr::na if() - replace specific values with NA pmax() - element-wise max()

pmin() - element-wise min() dplyr::recode() - Vectorized switch() dplyr::recode_factor() - Vectorized switch() for factors

Summary Functions

TO USE WITH SUMMARISE ()

summarise() applies summary functions to columns to create a new table. Summary functions take vectors as input and return single values as output.

summary function

COUNTS

dplyr::n() - number of values/rows dplyr::n distinct() - # of uniques sum(!is.na()) - # of non-NA's

LOCATION mean() - mean, also mean(!is.na()) median() - median

LOGICALS

mean() - Proportion of TRUE's sum() - # of TRUE's

POSITION/ORDER

dplyr::first() - first value

dplyr::last() - last value dplyr::nth() - value in nth location of vector

quantile() - nth quantile min() - minimum value max() - maximum value

IOR() - Inter-Quartile Range mad() - median absolute deviation sd() - standard deviation var() - variance

Row Names

Tidy data does not use rownames, which store a variable outside of the columns. To work with the rownames, first move them into a column.





Also has rownames() remove rownames()

Combine Tables

COMBINE VARIABLES



Use bind_cols() to paste tables beside each other as they are.

bind cols(...) Returns tables placed side by side as a single table BE SURE THAT ROWS ALIGN.

Use a "Mutating Join" to join one table to columns from another, matching values with the rows that they correspond to. Each join retains a different combination of values from the tables.









Use a named vector. by = c("col1" = "col2"), to match on columns with different names in each data set. left_loin(x, v, by = c("C" = "D"))

> Use suffix to specify suffix to give to duplicate column names left_join(x, y, by = c("C" = "D"), suffix =

COMBINE CASES



Use bind_rows() to paste tables below each other as they are.













retains duplicates.

Use a "Filtering Join" to filter one table against the rows of another



ments anti join(x, v, by = NULL, ...) Return rows of x that do not have a match in v. USEFUL TO SEE WHAT WILL NOT BE JOINED.

Suggested Readings

- R for Data Science
 - https://r4ds.had.co.nz
- [R4DS] Ch7. Tibbles with tibble
 - https://r4ds.had.co.nz/wrangle-intro.html
 - https://r4ds.had.co.nz/tibbles.html
- [R4DS] Ch10. Relational Data with dplyr
 - https://r4ds.had.co.nz/relational-data.html

Exercise

• In Ch10@R4DS, is there a relationship between the age of the plane and its delay? Write one-page report.

데이터 시각화 41 / 41 R05. Data Transformation