Sim, Min Kyu, Ph.D. mksim@seoultech.ac.kr



데이터 시각화 1 / 32 R06. Tidy data

- 1. Tidy data
- $\bigcirc$  II. Long  $\longleftrightarrow$  Wide (tidyr)
- 3 III. Split vs Concatenate (tidyr or stringr)
- 4 IV. Join (dplyr)
- 🧿 V. NA의 처리

데이터 시각화 2 / 32 R06. Tidy data

I. Tidy data

•000

I. Tidy data

데이터 시각화 3/32 R06. Tidy data

```
library(dplyr)
library(tidvr)
```

I. Tidy data

0000

#### Tidy data set

• dplyr은 tidy data. frame 자료 구조를 다루는 함수를 제공한다.

dplyr functions work with pipes and expect tidy data. In tidy data:



그림 1: tidy dataset (from dplyr cheatsheet)

- What is "tidy dataset"?
  - 1. data.frame의 자료 구조
  - 2. 각각의 row는 관찰값
  - 3. 각각의 column은 변수

데이터 시각화 4 / 32 R06. Tidy data

## Advantages of "tidy dataset"

- 1. 일관된 방식으로 저장되어 이해하기 쉽다.
- 2. Vectorized programming의 속성이 발휘된다.
- 3. 대부분의 tidyverse 라이브러리(ggplot2 포함)는 tidy 데이터셋을 가정한다.

데이터 시각화 5 / 32 R06. Tidy data

| I. Tidy data   |   | Concatenate (tidyr or stringr)<br>O  | IV. Join (dpLyr) V. NA의 처리<br>00000000 000000  |
|--|---|--|--|
| table1   |   | table3   |  |
| ## <chr> <br/>## 1 Afghanistan<br/>## 2 Afghanistan<br/>## 3 Brazil<br/>## 4 Brazil<br/>## 5 China</chr>   | year cases population<br>(int) <int> <int><br/>1999 745 19987071<br/>2000 2666 20595360<br/>1999 37737 172006362<br/>2000 80488 174504898<br/>1999 212258 1272915272<br/>2000 213766 1280428583</int></int> | ## * <chr> <int> ## 1 Afghanistan 1995 ## 2 Afghanistan 2006 ## 3 Brazil 1995 ## 4 Brazil 2006 ## 5 China 1995</int></chr> | rate<br>cchr><br>745/19987071<br>2666/20595360<br>37737/172006362<br>80488/174504898<br>212258/1272915272<br>213766/1280428583 |
| ## # A tibble: 12 ## country ## <ch> ## 1 Afghanistan ## 2 Afghanistan ## 3 Afghanistan ## 4 Afghanistan ## 5 Brazil ## 6 Brazil ## 7 Brazil ## 8 Brazil ## 9 China</ch> | year type count <int> <chr> <chr> <int> <chr> <chr> 1999 cases 745 1999 population 19987071 2000 cases 2666</chr></chr></int></chr></chr></int>   | ## * <chr></chr>   |  |
| ## 10 China  | 1999 population 1272915272  |  | 915272 1280428583  |
| ## 11 China<br>ଔ   | 2000 cases 213766<br>이터 시각화   | 6/32   | R06. Tidy data   |

II. Long  $\longleftrightarrow$  Wide (tidyr)

데이터 시각화 7 / 32 R06. Tidy data

# Long to Wide (spread)

#### Before (too long)

```
table2
  # Δ tibble: 12 x 4
##
      country
                                          count
                   year type
##
      <chr>>
                  <int> <chr>
                                          <int>
##
    1 Afghanistan
                   1999 cases
                                            745
    2 Afghanistan
                   1999 population
##
                                      19987071
    3 Afghanistan
                   2000 cases
                                          2666
##
##
    4 Afghanistan
                   2000 population
                                      20595360
##
    5 Brazil
                   1999 cases
                                          37737
##
    6 Brazil
                   1999 population
                                     172006362
    7 Brazil
                   2000 cases
                                          80488
##
##
    8 Brazil
                   2000 population
                                     174504898
##
    9 China
                   1999 cases
                                        212258
## 10 China
                   1999 population 1272915272
## 11 China
                   2000 cases
                                        213766
## 12 China
                    2000 population 1280428583
```

#### After (tidy)

```
table1
## # A tibble: 6 x 4
##
     country
                        cases population
                  year
##
     <chr>>
                 <int>
                        <int>
                                    <int>
## 1 Afghanistan
                  1999
                           745
                                 19987071
## 2 Afghanistan
                                 20595360
                  2000
                         2666
## 3 Brazil
                         37737
                               172006362
                  1999
## 4 Brazil
                  2000
                        80488
                                174504898
## 5 China
                  1999 212258 1272915272
## 6 China
                  2000 213766 1280428583
```

#### spread: Long to Wide

```
table2 %>% spread(key = "type", value = "count")
```

데이터 시각화 8 / 32 R06. Tidy data

## spread: Long to Wide

```
table2 %>% spread(key = "type", value = "count")
## # A tibble: 6 x 4
##
     country
                year cases population
##
     <chr>>
                 <int>
                        <int>
                                   <int>
## 1 Afghanistan
                 1999
                          745
                                19987071
## 2 Afghanistan
                  2000
                         2666
                                20595360
## 3 Brazil
                  1999
                        37737
                               172006362
## 4 Brazil
                  2000
                       80488
                               174504898
## 5 China
                  1999 212258 1272915272
## 6 China
                  2000 213766 1280428583
```

데이터 시각화 9 / 32 R06. Tidy data

# Wide to Long (gather)

#### Before (too wide)

```
table4a
## # A tibble: 3 x 3
     country
                 `1999` `2000`
##
## * <chr>
                  <int>
                        <int>
## 1 Afghanistan
                    745
                           2666
## 2 Brazil
                  37737
                         80488
## 3 China
                 212258 213766
table4b
## # A tibble: 3 x 3
     country
                      `1999`
                                 `2000`
```

<int>

1272915272 1280428583

19987071

172006362

<int>

20595360

174504898

# After (tidy)

```
table1
## # A tibble: 6 x 4
     country
                        cases population
##
                  year
##
     <chr>>
                 <int>
                        <int>
                                   <int>
## 1 Afghanistan
                  1999
                          745
                                19987071
## 2 Afghanistan
                                20595360
                  2000
                         2666
## 3 Brazil
                        37737
                               172006362
                  1999
## 4 Brazil
                  2000
                        80488
                               174504898
## 5 China
                  1999 212258 1272915272
## 6 China
                  2000 213766 1280428583
```

# gather: Wide to Long

## \* <chr>

## 3 China

## 1 Afghanistan ## 2 Brazil

```
tidy4a <- table4a %>% gather("1999", "2000", key = "year", value = "cases")
tidy4b <- table4b %>% gather("1999", "2000", key = "year", value = "cases")
```

데이터 시각화 10 / 32 R06. Tidy data

```
tidv4a <- table4a %>% gather("1999", "2000", key = "year", value = "cases")
tidv4a
## # A tibble: 6 x 3
##
     country
                 vear
                         cases
##
     <chr>>
                 <chr>>
                        <int>
## 1 Afghanistan 1999
                           745
## 2 Brazil
                 1999
                         37737
## 3 China
                 1999
                        212258
                          2666
## 4 Afghanistan 2000
## 5 Brazil
                 2000
                        80488
## 6 China
                 2000
                        213766
tidy4b <- table4b %>% gather("1999", "2000", key = "year", value = "population")
tidy4b
## # A tibble: 6 x 3
##
                        population
     country
                 year
```

• The last piece of puzzle - tidy4a와tidy4b를 어떻게 결합할까??

##

<chr>>

## 2 Brazil

## 3 China

## 5 Brazil

## 6 China

## 1 Afghanistan 1999

## 4 Afghanistan 2000

<chr>>

1999

1999

2000

2000

<int>

19987071

172006362

1272915272

20595360

174504898

1280428583

데이터 시각화 11 / 32 R06. Tidy data

# III. Split vs Concatenate (tidyr or stringr)

데이터 시각화 12 / 32 R06. Tidy data

# Before

```
## # A tibble: 3 x 3
## country year rate
## ' <chr> ## 1 Afghanistan 1999 745/19987071
## 2 Afghanistan 2000 2666/20595360
## 3 Brazil 1999 37737/172006362
```

# Aftertable1 %>% head(3)

```
## # A tibble: 3 x 4
    country
               year cases population
     <chr>>
                 <int> <int>
                                  <int>
##
## 1 Afghanistan 1999
                        745
                              19987071
## 2 Afghanistan
                       2666
                              20595360
                 2000
## 3 Brazil
                  1999 37737
                             172006362
```

#### 1) tidyr::separate()

데이터 시각화 R06. Tidy data

```
library(stringr)
temp <-
  str split(string = table3$rate, pattern = "/")
temp
## [[1]]
## [1] "745"
                  "19987071"
##
## [[2]]
## [1] "2666"
                  "20595360"
##
## [[3]]
## [1] "37737"
                    "172006362"
##
## [[4]]
## [1] "80488"
                    "174504898"
##
## [[5]]
## [1] "212258"
                     "1272915272"
##
## [[6]]
## [1] "213766"
                     "1280428583"
```

- 결과물이 list의 형태로 나오며, 각 list의 element는 vector
- 해당 list의 각 원소인 vector에서
  - 1. 벡터의 첫 번째 원소가 cases
  - 2. 벡터의 두 번째 원소가 population
- 아래의 sapply()함수를 사용할 수 있지 않을까?

```
sapply(temp, function(x) x[1])
## [1] "745" "2666" "37737" "80488" "212258" "21
sapply(temp, function(x) x[2])
## [1] "19987071" "20595360" "172006362" "1745048
## [6] "1280428583"
```

```
table3$cases <-
   str_split(string = table3$rate, pattern = "/") %>% sapply(function(x) x[1])
table3$population <-
   str_split(string = table3$rate, pattern = "/") %>% sapply(function(x) x[2])
table3 %>% select(-rate) # display after removing the original variable `rate`
```

```
##
    country
                             population
                year cases
##
     <chr>>
                <int> <chr> <chr>
## 1 Afghanistan 1999 745
                             19987071
## 2 Afghanistan 2000 2666
                             20595360
## 3 Brazil
                 1999 37737 172006362
## 4 Brazil
                 2000 80488 174504898
## 5 China
                 1999 212258 1272915272
## 6 China
                 2000 213766 1280428583
```

## # A tibble: 6 x 4

• stringr 패키지의 함수는 list형을 반환하기 때문에 어렵게 느껴질수도 있지만 매우 빠른 처리를 해주는 장점이 있다.

데이터 시각화 15 / 32 R06. Tidy data

# Another example of tidyr::separate

```
table1 %>% separate(year, into = c("century", "year"), sep = 2)
## # A tibble: 6 x 5
##
     country
                 century year
                                 cases population
##
     <chr>>
                 <chr>>
                         <chr>>
                                 <int>
                                            <int>
## 1 Afghanistan 19
                         99
                                   745
                                         19987071
## 2 Afghanistan 20
                         00
                                  2666
                                         20595360
## 3 Brazil
                 19
                         99
                                 37737
                                        172006362
## 4 Brazil
                 20
                         00
                                 80488
                                        174504898
## 5 China
                 19
                         99
                                212258 1272915272
## 6 China
                 20
                         00
                                213766 1280428583
```

데이터 시각화 16 / 32 R06. Tidy data

# Concatenating

## 4 Brazil

```
    Before

                                                       After
table1
                                                    table3
## # A tibble: 6 x 4
                                                    ## # A tibble: 6 x 5
     country
                         cases population
                                                        country
                                                                                      cases population
##
                  year
                                                                    year rate
##
     <chr>>
                 <int>
                         <int>
                                    <int>
                                                         <chr>>
                                                                    kint> kchr>
                                                                                         kchr> kchr>
## 1 Afghanistan
                  1999
                           745
                                 19987071
                                                    ## 1 Afghanistan 1999 745/19987071
                                                                                           745
                                                                                                 19987071
                                 20595360
                                                    ## 2 Afghanistan 2000 2666/20595360
                                                                                                 2059536
## 2 Afghanistan
                  2000
                          2666
                                                                                           2666
## 3 Brazil
                  1999
                         37737
                                172006362
                                                    ## 3 Brazil
                                                                                          37737 17200636
                                                                    1999 37737/172006362
## 4 Brazil
                   2000
                         80488
                                174504898
                                                    ## 4 Brazil
                                                                    2000 80488/174504898
                                                                                          80488 17450489
## 5 China
                  1999 212258 1272915272
                                                    ## 5 China
                                                                   1999 212258/1272915272 212258 1272915
## 6 China
                   2000 213766 1280428583
                                                    ## 6 China
                                                                   2000 213766/1280428583 213766 1280428
1) Concatenate using tidyr::unite()
table1 %>% unite(rate, cases, population, sep = "/")
```

```
# A tibble: 6 x 3
##
     country
                  year rate
##
     <chr>>
                 <int> <chr>
## 1 Afghanistan 1999 745/19987071
## 2 Afghanistan 2000 2666/20595360
## 3 Brazil
                  1999 37737/172006362
```

2000 80488/174504898

table1\$rate <- paste(table1\$cases, table1\$population, sep="/")

# 2) Or, simply use base::paste()

```
table1
## # A tibble: 6 x 5
     country
                 year cases population rate
##
##
     <chr>>
                 <int>
                        <int>
                                   <int> <chr>
## 1 Afghanistan 1999
                          745
                               19987071 745/19987071
  2 Afghanistan
                  2000
                         2666
                                20595360 2666/20595360
## 3 Brazil
                  1999
                        37737
                               172006362 37737/172006362
## 4 Brazil
                  2000
                        80488
                              174504898 80488/174504898
## 5 China
                  1999 212258 1272915272 212258/1272915272
## 6 China
                  2000 213766 1280428583 213766/1280428583
```

데이터 시각화 18 / 32 R06. Tidy data

IV. Join (dpLyr)

데이터 시각화 19 / 32 R06. Tidy data

## Dataset

## 2

## 3

4 Seoul

6 Busan

```
df1 <- data.frame(CustomerId = c(1:5), Product = c(rep("Toaster", 3), rep("Radio", 2)))</pre>
df2 <- data.frame(CustomerId = c(2, 4, 6), State = c(rep("Seoul", 2), rep("Busan", 1)))</pre>
df1
     CustomerId Product
##
## 1
              1 Toaster
## 2
              2 Toaster
## 3
              3 Toaster
## 4
                 Radio
## 5
                 Radio
df2
##
     CustomerTd State
## 1
              2 Seoul
```

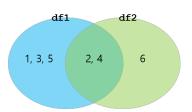
• df1과 df2를 어떻게 합해야 하는가? 어느쪽이 primary key인가? 결측치가 생겨도 상관없는가?

```
library(dplyr)
library(sqldf) # Enables to use SQL syntax in R
```

데이터 시각화 20 / 32 R06. Tidy data

# Join(Merge)의 4가지 모드

```
df1
     CustomerId Product
## 1
              1 Toaster
## 2
              2 Toaster
## 3
              3 Toaster
## 4
                   Radio
## 5
                   Radio
df2
     CustomerId State
##
## 1
              2 Seoul
## 2
              4 Seoul
## 3
              6 Busan
```



- 1. inner
- 2. left
- 3. full (outer)
- 4. right

데이터 시각화 21 / 32 R06. Tidy data

Radio Seoul

# 1. Inner join

## 2

```
inner_join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId") # base
sqldf("SELECT * FROM df1 JOIN df2 USING(CustomerID)") # sqldf
## Joining, by = "CustomerId"
## CustomerId Product State
## 1 2 Toaster Seoul
```

데이터 시각화 22 / 32 R06. Tidy data

# 2. Left join

```
left join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId", all.x = TRUE) # base
sqldf("SELECT * FROM df1 LEFT JOIN df2 USING(CustomerID)") # sqldf
## Joining, by = "CustomerId"
##
    CustomerId Product State
## 1
              1 Toaster <NA>
## 2
              2 Toaster Seoul
## 3
              3 Toaster <NA>
## 4
                 Radio Seoul
                 Radio <NA>
## 5
```

데이터 시각화 23 / 32 R06. Tidy data

# 3. Outer join (full)

```
full join(df1, df2) # dplyr
merge(x = df1, y = df2, by = "CustomerId", all = TRUE) # base
# sqldf does not support FULL JOIN, needing three lines.
a <- sqldf("SELECT * FROM df1 LEFT JOIN df2 USING(CustomerID)")
b <- sqldf("SELECT * FROM df2 LEFT JOIN df1 USING(CustomerID)")</pre>
union(a,b)
## Joining, by = "CustomerId"
     CustomerId Product State
## 1
              1 Toaster <NA>
## 2
              2 Toaster Seoul
## 3
              3 Toaster <NA>
## 4
                  Radio Seoul
## 5
                 Radio <NA>
## 6
              6
                <NA> Busan

    Set operations
```

- union(a,b)
- intersect(a,b)
- setdiff(a,b)
- setdiff(b,a)

데이터 시각화 24 / 32 R06. Tidy data

right join(df1, df2) # dplyr

# 4. Right join

데이터 시각화 25 / 32 R06. Tidy data

- join할때 사용할 key 변수의 지정
- by = argument로 key 변수를 아래처럼 지정한다.
- by = 을 입력하지 않으면 같은 이름의 변수를 찾아서 자동으로 key로 사용한다.

```
inner_join(df1, df2)
inner_join(x=df1, y=df2)
inner_join(x=df1, y=df2, by = "CustomerId")
inner_join(x=df1, y=df2, by = c("CustomerId"))
inner_join(x=df1, y=df2, by = c("CustomerId"="CustomerId"))
```

- vlookup()이나 index()-match()함수를 이용해서 엑셀 파일 합해본 경험있나요?
- R에서는 훨씬 간단하게 dataset을 합칠 수 있다.
- 데이터의 각 관찰값들에 대해 primary key 변수를 가지고 관리되고 있는가?
- 만약에 아니라면 직관적인 처리를 위해서 만드는 것이 좋다.
- key 변수는 알기 쉽고, 중복되지 않고, 체계적인 규칙을 가지고 있어야 한다.

데이터 시각화 26 / 32 R06. Tidy data

V. NA의 처리

#### Motivation

- 여러가지 이유로 아래와 같이 NA (결측치, Not Available)가 생긴다.
- 주로 3가지 방법으로 해결한다.

df3 <- full join(df1, df2)

1. 결측치가 있는 관찰값을 제거

df3\$Population <- c(NA, 1000, NA, 1000, NA, 200)

- 2. 그대로 두고 함수를 적용할 때 주의해서 분석
- 3. 결측치를 다른 수치로 대체 (평균, 0 등의 값)

```
df3
##
     CustomerId Product State Population
## 1
              1 Toaster <NA>
                                      NΔ
## 2
              2 Toaster Seoul
                                    1000
## 3
              3 Toaster <NA>
                                      NA
## 4
                  Radio Seoul
                                    1000
## 5
                  Radio <NA>
                                      NΔ
## 6
                 <NA> Busan
                                     200
```

데이터 시각화 28 / 32 R06. Tidy data

## 1. 결측치가 있는 관찰값을 제거하기

#### dplyr

```
## CustomerId Product State Population
## 1 2 Toaster Seoul 1000
## 2 4 Radio Seoul 1000
## 3 6 <NDA Busan 200
```

df3 %>% filter(!is.na(State))

#### base

## 4

## 6

```
is.na(df3$State)
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
is.na(df3$State) %>% which()
## [1] 1 3 5
df3[-(is.na(df3$State) %>% which()),]
## CustomerId Product State Population
## 2 2 Toaster Seoul 1000
```

Radio Seoul

<NA> Busan

1000

200

 아래 명령들도 같은 결과를 만들어 낸다.

```
df3[!is.na(df3$State),]
df3[which(!is.na(df3$State)),]
```

데이터 시각화 29 / 32 R06. Tidy data

## [1] 461.8802

# 2. 그대로 두고 함수를 적용할 때 주의해서 분석

• 많은 함수들에서 na.rm=TRUE의 옵션(remove na)이 사용이 가능하다.

```
mean(df3$Population)
## [1] NA
mean(df3$Population, na.rm = TRUE)
## [1] 733.3333
sd(df3$Population)
## [1] NA
sd(df3$Population, na.rm = TRUE)
```

데이터 시각화 30 / 32 R06. Tidy data

# 3. 결측치를 다른 수치로 대체하기 (평균, 0등의 값)

#### dplyr

```
df3 %>% mutate(
  Population =
    if else(
      is.na(Population), # Condition
      mean(Population, na.rm = TRUE), # If TRUE
      Population)) # If FALSE
```

```
CustomerId Product State Population
##
## 1
              1 Toaster <NA>
                                 733.3333
## 2
              2 Toaster Seoul
                                1000.0000
## 3
              3 Toaster <NA>
                                 733.3333
## 4
                  Radio Seoul
                                1000,0000
## 5
                  Radio <NA>
                                 733.3333
## 6
                   <N∆> Busan
                                 200.0000
              6
```

#### base

```
is.na(df3$Population)
## [1] TRUE FALSE TRUE FALSE TRUE FALSE
df3$Population[is.na(df3$Population)] <-
  mean(df3$Population, na.rm = TRUE)
df3
```

IV. Join (dpLyr)

```
##
     CustomerId Product State Population
## 1
              1 Toaster <NA>
                                733.3333
## 2
              2 Toaster Seoul
                               1000.0000
## 3
              3 Toaster <NA>
                                733.3333
## 4
                  Radio Seoul
                               1000.0000
## 5
                  Radio <NA>
                                733.3333
## 6
                   <NA> Busan
                                200,0000
```

데이터 시각화 31 / 32 R06. Tidy data

#### **Suggested Readings**

- R for Data Science
  - https://r4ds.had.co.nz
- [R4DS] Ch8. Data Import with readr
  - https://r4ds.had.co.nz/data-import.html
- [R4DS] Ch9. Tidy Data with tidyr
  - https://r4ds.had.co.nz/tidy-data.html

#### Exercise

 In Ch9@R4DS, are iso2 and iso3 are redundant with country? Write one page report.

데이터 시각화 32 / 32 R06. Tidy data