R07. ggplot (1)

Basic commands

Sim, Min Kyu, Ph.D. mksim@seoultech.ac.kr



데이터 시각화 1 / 33 R07. ggplot (1)

- I. Getting started with ggpLot2 and mpg
- II. Scatterplot for displ and hwy
- ③ III. Faceting (분할 배열)

데이터 시각화 2 / 33 R07. ggplot (1)

I. Getting started with ggpLot2 and mpg

데이터 시각화 3 / 33 R07. ggplot (1)

ggpLot2 라이브러리

About

- Data visualization package for R, created by Hadley Wickham in 2005.
- ggplot2 is an implementation of Leland Wilkinson's Grammar of Graphics, whose scheme breaks up graphs into semantic components such as scales and layers.

```
install.packages("ggplot2")
library(ggplot2)
```

데이터 시각화 4 / 33 R07. ggplot (1)

mpa 데이터셋

About

- ggplot2 패키지에 내장된 데이터셋
- 1999년과 2008년에 생산된 38개 차량모델들의 연비 데이터
- 데이터셋 diamond, iris와 함께 R에서 가장 많이 예제로 쓰임
- 아래의 명령어로 built-in documentation 조회 가능

? mpg help(mpg)



데이터 시각화 5/33 R07, gaplot (1)

Overview

```
str(mpg)
## tibble [234 x 11] (S3: tbl df/tbl/data.frame)
## $ manufacturer: chr [1:234] "audi" "audi" "audi" "audi" ...
## $ model
                 : chr [1:234] "a4" "a4" "a4" "a4" ...
## $ displ
                 : num [1:234] 1.8 1.8 2 2 2.8 2.8 3.1 1.8 1.8 2 ...
## $ year
                 : int [1:234] 1999 1999 2008 2008 1999 1999 2008 1999 1999 2008 ...
## $ cvl
                 : int [1:234] 4 4 4 4 6 6 6 4 4 4 ...
## $ trans
                 : chr [1:234] "auto(15)" "manual(m5)" "manual(m6)" "auto(av)" ...
                 : chr [1:234] "f" "f" "f" "f" ...
## $ drv
## $ cty
                 : int [1:234] 18 21 20 21 16 18 18 18 16 20 ...
                 : int [1:234] 29 29 31 30 26 26 27 26 25 28 ...
## $ hwv
## $ fl
                 : chr [1:234] "p" "p" "p" "p" ...
## $ class
                 : chr [1:234] "compact" "compact" "compact" "compact" ...
```

Variables

Name	Description	Туре
manufacturer	제조사	chr
model	차종	chr
displ	엔진크기	num
year	생산연도	int
cyl	기통	int
trans	트랜스미션	chr
drv	전륜(f)/후륜(r)/사륜(4)	chr
cty	도심 연비	int
hwy	고속도로 연비	int
fl	연료종류 (fuel)	chr
class	타입 (세단, 트럭, SUV,···)	chr

데이터 시각화 7 / 33 R07. ggplot (1)

II. Scatterplot for displ and hwy

데이터 시각화 8 / 33 R07. ggplot (1)

Motivation

- Q. 엔진의 용량과 연비는 어떤 관계가 있는가?
- 엔진용량(disp1)과 고속도로연비(hwy)는 각각 num(수치형)과 int(정수형)의 데이터 타입을 가지고 있다.
- 둘 다 수치변수(사칙연산이 가능함)이므로 산점도를 그려서 조사해보자.
 - 원인에 해당하는 엔진크기(displ)를 X축
 - 결과에 해당하는 고속도로연비(hwy)를 Y축

데이터 시각화 9 / 33 R07. ggplot (1)

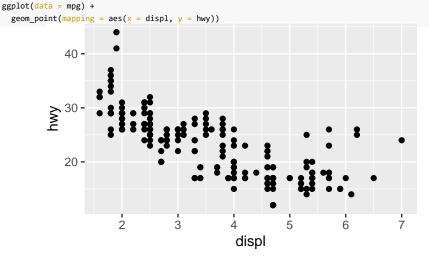


그림 1: 엔진의 크기와 연비의 관계

• 위의 그림으로 보아 엔진의 용량과 연비는 어떤 관계가 있는가?

데이터 시각화 10 / 33 R07. ggplot (1)

Basic Syntax

• 위의 플랏을 그리기 위해 아래의 명령어가 사용되었다.

```
# The plot above
ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy))
```

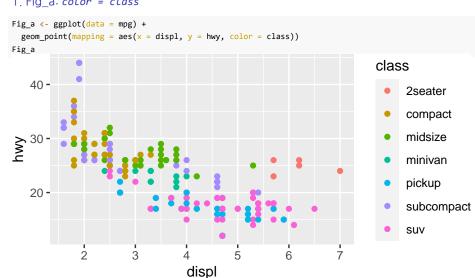
- 가장 minimal한 ggplot2의 명령어는 아래와 같다.
 - <DATA> 데이터프레임을 지정한다.
 - <GEOM FUNCTION> 데이터를 어떤 모양으로 표현할 것인지를 결정한다.
 - ex) point, line, curve, bar, histogram, text, label, and so on
 - <MAPPING> 변수를 시각요소(aesthetic)에 대응시킨다.
 - ex) position(x, y), size, line width, color, line type, and so on.

Adding the variable class to the scatterplot.

- 앞의 산점도에 class 변수(차량의 타입)을 추가하여 다시 그려보자.
- 몇 가지의 방법의 aesthetic mapping을 생각할 수 있다.
 - 1. Fig_a: 점의 색깔을 class 값에 따라서 다르게 한다. (color=class)
 - 2. Fig_b: 점의 크기를 class 값에 따라서 다르게 한다.(size=class)
 - 3. Fig_c: 점의 진하기를 class 값에 따라서 다르게 한다.(alpha=class)
 - 4. Fig_d: 점의 모양을 class 값에 따라서 다르게 한다.(shape=class)

데이터 시각화 12 / 33 R07. ggplot (1)

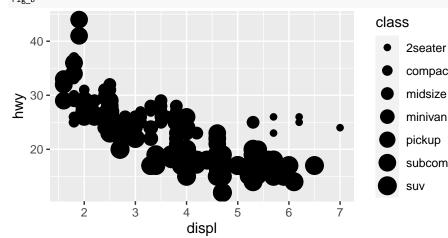
1. Fig_a: color = class



데이터 시각화 13 / 33 R07, gaplot (1)

2. Fig b: size = class

```
Fig_b <- ggplot(data = mpg) +
 geom_point(mapping = aes(x = displ, y = hwy, size = class))
Fig_b
```



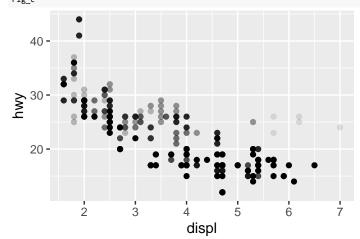
14/33

- 2seater
- compact
- minivan
 - pickup
- subcompact
 - suv

R07. ggplot (1)

3. Fig_c: alpha = class

```
Fig_c <- ggplot(data = mpg) +
   geom_point(mapping = aes(x = displ, y = hwy, alpha = class))
Fig_c</pre>
```

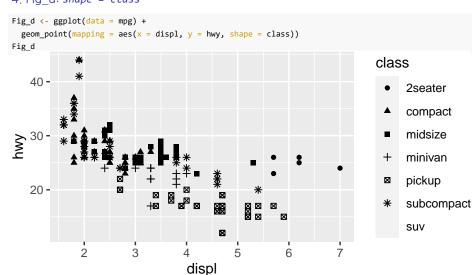


class

- 2seater
- compact midsize
- minivan
- pickup
- subcompact
- suv

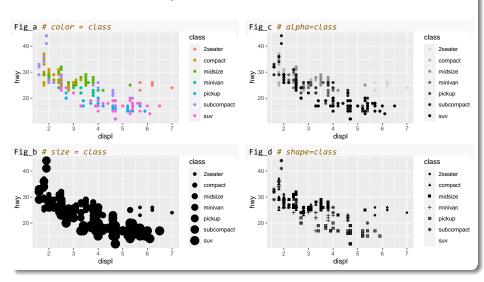
데이터 시각화 15 / 33 R07. ggplot (1)

4. Fig_d: shape = class



Discussion on Fig_a, Fig_b, Fig_c, and Fig_d

• What is the best and why?



Proper vs Improper aesthetic mapping

- 앞의 그림에는 아래와 같은 aesthetic mapping이 적용되었다.
 - 1. Fig_a: 점의 색깔(color)이 class 값에 따라서 **달라진다**. (color=class)
 - 2. Fig_b: 점의 크기(size)가 class 값에 따라서 **크고 작다**. (size=class)
 - 3. Fig_c: 점의 진하기(alpha)가 class 값에 따라서 **진하고 옅다**. (alpha=class)
 - 4. Fig_d: 점의 모양(shape)이 class 값에 따라서 **달라진다** (shape=class)
- class의 변수 값은 i) 달라지고, ii) 크고 작고, iii) 진하고 옅은 것에 연관시키는 것이 적합한가?
- class 변수는
 - ordered/unordered variable?
 - discrete/continuous variable?

Basic rule for aesthetic mapping

	ordered/unordered	discrete/conti.	others
color	unordered	discrete	color display
size	ordered	•	•
alpha	ordered	•	bounded
shape	unordered	discrete	b/w display

- color나 shape를 사용할 때에는 magic number 7에 주의해야 한다. 아래의 대안을 고려할 수 있다.
 - further grouping
 - faceting
 - 다른 geometric object (line, smooth, path)
- alpha is more suitable than size if bounded.
 - 흔히 0과 1사이의 값에 해당됨
 - 농도, 비율, 빈도, 확률, Intensity.

데이터 시각화 19 / 33 R07. ggplot (1)

R에서 제공하는 warning messages

- Fig_b (size=class)
 - "Using size for a discrete variable is not advised."
- Fig_c (alpha=class)
 - "Using alpha for a discrete variable is not advised."
- Fig d (shape=class)
 - 1: The shape palette can deal with a maximum of 6 discrete values because more than 6 becomes difficult to discriminate; you have 7. Consider specifying shapes manually if you must have them.
 - 2: Removed 62 rows containing missing values (geom point).

The best so far?

```
```{r, out.height='60%', fig.asp=0.6, fig.width=5, fig.cap="The best so far?"}
ggplot(data = mpg) +
 geom_point(mapping = aes(x = displ, y = hwy, color=class, shape=class))
```

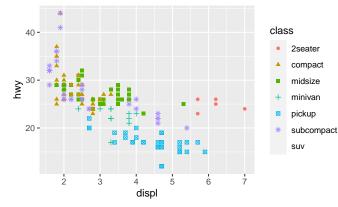


그림 2: The best so far?

### Chunk figuration for rmd output

- fig.width and fig.height
  - The size of R plots in inches.
  - Alternatively, the two options together in a single chunk option fig.dim
    - e.g., fig.dim = c(6, 4) means fig.width = 6 and fig.height = 4.
- out.width and out.height
  - The output size of R plots in the output document.
  - e.g., out.width = '80%' means 80% of the page width.
- fig.asp
  - 1.6 or 0.625 for "golden ratio".
- fig.align
  - The alignment of plots, which can be 'left', 'center', or 'right'.
- fig.cap
  - The figure caption

데이터 시각화 22 / 33 R07. ggplot (1)

#### Review

```
ggplot(data = mpg) + geom_point(mapping = aes(x = displ, y = hwy))
ggplot(data = <DATA>) + <GEOM_FUNCTION>(mapping = aes(<MAPPING>))

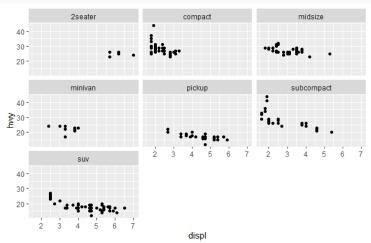
Fig_a <- ggplot(data = mpg) + geom_point(mapping = aes(x = displ, y = hwy, color = class))
Fig_b <- ggplot(data = mpg) + geom_point(mapping = aes(x = displ, y = hwy, size = class))
Fig_c <- ggplot(data = mpg) + geom_point(mapping = aes(x = displ, y = hwy, alpha = class))
Fig_d <- ggplot(data = mpg) + geom_point(mapping = aes(x = displ, y = hwy, shape = class))

ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy, color=class, shape=class))</pre>
```

III. Faceting (분할 배열)

# facet\_wrap() to add one dimension

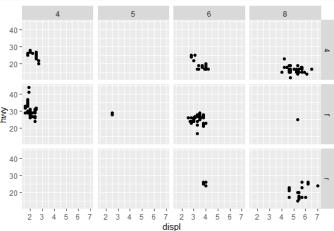
```
ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy)) +
facet_wrap(~ class)
```



데이터 시각화 25 / 33 R07. ggplot (1)

# facet\_grid() to increment two dimensions

```
ggplot(data = mpg) +
geom_point(mapping = aes(x = displ, y = hwy)) +
facet_grid(drv ~ cyl)
```



● drv를 y축(세로)으로 cy1을 x축(가로)으로 grid 배열

# Yes or No to faceting?

- Yes to faceting
  - 1. Data가 충분히 많을 때
  - 2. Categorical 변수의 값에 대해 각각의 distribution을 보고 싶을 때
- No faceting
  - 1. 근접 비교를 하고 싶을 때
  - 2. Reader들의 사전 지식 수준이 높을때
- Presentation flow
  - 1. 전체 그림 → Zooming in
  - 2. No facet  $\rightarrow$  Yes facet
  - 3. Top-down approach

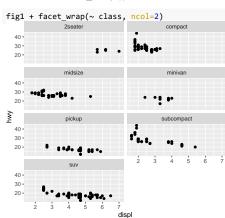
데이터 시각화 27 / 33 R07. ggplot (1)

# Additive Implementation

fig1 <- ggplot(data = mpg) + geom\_point(mapping = aes(x = displ, y = hwy))

Original

 Add facet\_wrap()

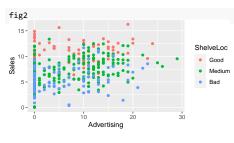


• 그림의 특징을 더하기 위해 코드를 더하는 방식으로 구현

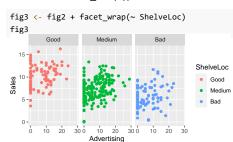
데이터 시각화 28 / 33 R07. ggplot (1)

# Rearranging factor variable

### Original



## Add facet\_wrap()



데이터 시각화 29 / 33 R07. ggplot (1)

### Versatile addtivity

fig4 <- ggplot( $\frac{data}{data}$  = Carseats,  $\frac{data}{data}$ fig4 fig4 + facet\_wrap(~ Urban) Yes 15-15 -Urban 10-Sales Urban Sales - 01 Nο No Yes 5 -Yes 0 -0 -10 20 20 20 30 10 30 0 10 Advertising Advertising fig4 + geom smooth(se=FALSE) fig4 + facet\_wrap(~ Urban) + geom\_smooth(se=FALSE) ula No Yes ula 15-15 - ( Urban Sales Urban Sales 10 No No Yes 5 -Yes 0-0 -20 20 10 30 0 Ó 10 20 30 Advertising Advertising

#### Review

```
ggplot(data = mpg) +
 geom_point(mapping = aes(x = displ, y = hwy)) +
 facet wrap(~ class)
ggplot(data = mpg) +
 geom point(mapping = aes(x = displ, y = hwy)) +
 facet grid(drv ~ cyl)
fig1 <- ggplot(data = mpg) + geom point(mapping = aes(x = displ, y = hwy))
fig1 + facet wrap(~ class, ncol=2)
fig2 <- ggplot(Carseats %>%
 mutate(ShelveLoc = factor(ShelveLoc, levels = c("Good", "Medium", "Bad"))) %>%
 arrange(ShelveLoc)) +
 geom point(aes(x = Advertising, v = Sales, color = ShelveLoc))
fig3 <- fig2 + facet wrap(~ ShelveLoc)
fig4 \leftarrow ggplot(data = Carseats, aes(x = Advertising, y = Sales)) + geom point(aes(color = Urban))
fig4 + geom smooth(se=FALSE)
fig4 + facet wrap(~ Urban)
fig4 + facet wrap(~ Urban) + geom smooth(se=FALSE)
```

# Suggested Readings

- R for Data Science
  - https://r4ds.had.co.nz
- [R4DS] Ch1. Data Visualization with ggplot2
  - https://r4ds.had.co.nz/data-visualisation.html

데이터 시각화 32 / 33 R07. ggplot (1)

#### Exercise

• In Ch1@R4DS, make a scatterplot of hwy vs cyl as below.

- Analyze the vis in terms of the three step framework.
- Discuss this vis critically. Why is this vis poor?
- Describe the better alternative graphic in your mind by the three step framework.
- Provide a hand drawing of the ideal plot accordingly.